

Distribuição amostral, LGN e TCL

Métodos Quantitativos e Técnicas em Ciência Política I / Métodos III

Manoel Galdino

Retomada do curso — 2026

Objetivo: ligar estatística descritiva à inferência.

Roteiro:

- 1 revisão rápida: média, moda e mediana;
- 2 revisão rápida: variância e desvio-padrão;
- 3 população, amostra, parâmetro e estatística;
- 4 Lei dos Grandes Números;
- 5 distribuição amostral;
- 6 Teorema Central do Limite;
- 7 de onde vem o erro-padrão;
- 8 renda real e aproximação log-normal.

Leitura principal para esta aula:

Kellstedt e Whitten, Fundamentos da Pesquisa em Ciência Política, Capítulo 6, “Probabilidade e inferência estatística”.

Para revisar a primeira parte da aula:

Capítulo 5, especialmente a seção sobre como conhecer os dados estatisticamente e descrever variáveis contínuas.

Da aula passada para hoje

Na aula passada, probabilidade apareceu como linguagem da incerteza.

Hoje a pergunta muda:

se uma amostra é aleatória, o que podemos dizer sobre a estimativa que ela produz?

Para responder, precisamos relembrar como descrevemos uma distribuição.

O que é uma distribuição?

Uma distribuição mostra como os valores de uma variável se espalham.

Em termos simples:

- quais valores aparecem com frequência;
- qual é o valor típico;
- quão longe os casos ficam desse valor típico;
- se há assimetria ou valores extremos.

A média resume o centro pelo equilíbrio aritmético:

$$\bar{Y} = \frac{\sum_{i=1}^n Y_i}{n}$$

A mediana é o valor que divide a distribuição ao meio.

A moda é o valor mais frequente. Em variáveis contínuas, normalmente é aproximada pelo pico da densidade.

Três centros, uma distribuição




Figura 1: Média, mediana e moda em uma população simulada.

Tabela 1: Medidas descritivas da renda mensal simulada.

Medida	Valor
Média	R\$ 4.182
Mediana	R\$ 3.568
Moda aproximada	R\$ 2.326
Variância	7.947.867
Desvio-padrão	R\$ 2.819

Quando a média é maior que a mediana, há indício de assimetria à direita.

Isso costuma acontecer com renda:

- muitos casos ficam em valores baixos ou intermediários;
- poucos casos muito altos puxam a média para cima;
- a mediana pode descrever melhor o caso típico;
- a média continua sendo central para a inferência que veremos hoje.

Variância e desvio-padrão

A variância resume a distância quadrática média em relação à média:

$$s^2 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1}$$

O desvio-padrão é a raiz da variância:

$$s = \sqrt{s^2}$$

Ele volta para a unidade original da variável.

Mesma média, dispersão diferente




Figura 2: Duas distribuições com médias parecidas e dispersões diferentes.

Tabela 2: Média, variância e desvio-padrão em duas distribuições simuladas.

grupo	Média	Variância	Desvio-padrão
Grupo A: baixa variabilidade	50.0	25.9	5.1
Grupo B: alta variabilidade	50.7	302.0	17.4

Por que isso importa para inferência?

Inferência estatística começa com uma distinção:

Tabela 3: Médias de renda em seis amostras aleatórias de tamanho 100.

Amostra	Média da renda
Amostra 1	R\$ 4.824
Amostra 2	R\$ 3.773
Amostra 3	R\$ 4.546
Amostra 4	R\$ 4.316
Amostra 5	R\$ 4.340
Amostra 6	R\$ 3.992

A população é a mesma.

O sorteio muda.

população $\rightarrow$ amostra $\rightarrow$ estimativa

- Parâmetro: quantidade verdadeira na população. Geralmente não observamos.
- Estatística: quantidade calculada na amostra.
- Estimador: regra usada para calcular a estatística.
- Estimativa: valor observado em uma amostra específica.

A Lei dos Grandes Números diz que, sob amostragem aleatória, a média amostral se aproxima da média populacional quando n cresce.

$$\bar{Y}_n \xrightarrow{P} \mu$$

Intuição: erros para cima e para baixo vão se compensando quando a amostra cresce.

LGN em uma simulação




Figura 3: Convergência da média acumulada para a média populacional.

O que a LGN diz e não diz

A LGN diz:

- com amostras aleatórias grandes, a média amostral tende ao parâmetro;
- aumentar n reduz a chance de uma estimativa muito distante.

A LGN não diz:

- que uma amostra de conveniência melhora só por ser grande;
- qual é a forma da distribuição amostral;
- como calcular probabilidades em torno da estimativa.

Imagine repetir a pesquisa muitas vezes:

- 1 sorteamos uma amostra;
- 2 calculamos a média;
- 3 guardamos a média;
- 4 repetimos o processo.

A distribuição dessas médias é a distribuição amostral.

Distribuições amostrais da média




Figura 4: Distribuições amostrais da média para diferentes tamanhos de amostra.

Se $Y_1, Y_2, \dots, Y_n$ são variáveis aleatórias independentes e identicamente distribuídas, com média μ e variância finita σ^2 , então a soma padronizada se aproxima de uma Normal:

$$\frac{\sum_{i=1}^n Y_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$$

Independentes: o valor de uma observação não determina o valor da outra.

Identicamente distribuídas: todas vêm da mesma população.

Em uma amostra aleatória simples, cada unidade sorteada pode ser pensada como uma variável aleatória.

$$Y_1, Y_2, \dots, Y_n$$

Se sortearmos com reposição, essas variáveis são IID exatamente.

Se sortearmos sem reposição de uma população grande, elas são aproximadamente IID.

Essa é a conexão entre amostragem e o TCL.

Soma versus média

O TCL fala primeiro da soma:

$$S_n = \sum_{i=1}^n Y_i$$

Mas a média é apenas a soma dividida por n :

$$\bar{Y} = \frac{S_n}{n}$$

Por isso o mesmo resultado vale para a média padronizada:

$$\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

O que fica Normal?

A variável original não precisa ser Normal.

O que fica aproximadamente Normal é:

- a soma padronizada;
- ou a média padronizada;
- quando n cresce;
- sob independência, mesma distribuição e variância finita.

Isso é o que torna a média amostral previsível.

Por que o TCL importa?

O TCL permite transformar incerteza amostral em probabilidade.

Se sabemos que a distribuição amostral da média é aproximadamente Normal, podemos dizer quão provável é observar uma estimativa muito longe do parâmetro.

Essa é a ponte para:

- margem de erro;
- intervalo de confiança;
- teste de hipótese;
- p-valor.

De onde vem o erro-padrão

Se as observações são IID:

$$Var(Y_i) = \sigma^2$$

Para a soma:

$$Var\left(\sum_{i=1}^n Y_i\right) = n\sigma^2$$

Para a média:

$$Var(\bar{Y}) = Var\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{\sigma^2}{n}$$

A fórmula

O erro-padrão é o desvio-padrão da distribuição amostral de uma estatística.

Para a média:

$$SD(\bar{Y}) = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}$$

Como quase nunca conhecemos σ , usamos o desvio-padrão da amostra:

$$EP(\bar{Y}) \approx \frac{s}{\sqrt{n}}$$

O desvio-padrão descreve a dispersão dos indivíduos.

O erro-padrão descreve a dispersão das estimativas.

Erro-padrão e tamanho da amostra




Figura 5: Erro-padrão simulado e aproximação por s dividido pela raiz de n .

Renda real: distribuição assimétrica

Como exemplo real, vamos usar PIB per capita municipal como proxy de renda municipal.

Não é renda individual.

Mas serve para ver um padrão comum em variáveis econômicas: forte assimetria à direita.

Arquivo local: dados/pib_cid.RDS, PIB dos Municípios/IBGE, 2013.

PIB per capita municipal




Figura 6: Distribuição do PIB per capita municipal no Brasil, 2013.

Log-normal: a intuição correta

Muitas variáveis econômicas são aproximadas por uma log-normal.
Isso não quer dizer que a renda seja uma soma simples de choques.
Quer dizer algo mais preciso:

$$\log(Y) \approx X_1 + X_2 + \cdots + X_k$$

Então Y resulta de muitos fatores multiplicativos.

PIB per capita em escala log




Figura 7: Log do PIB per capita municipal e curva Normal ajustada.

O que esse exemplo mostra

No nível original, o PIB per capita municipal é muito assimétrico.

Na escala log, a distribuição fica bem mais próxima de uma Normal.

Esse é um primo conceitual do TCL:

- somas de muitos componentes tendem à Normal;
- produtos de muitos fatores viram somas depois do log;
- por isso variáveis positivas e muito assimétricas frequentemente parecem log-normais.

Tabela 4: Diferença entre LGN e TCL.

Resultado	Pergunta	Resposta
LGN	Para onde a média amostral vai quando n cresce?	Vai se aproximando da média populacional.
TCL	Que forma tem a distribuição amostral quando n cresce?	Aproxima-se de uma distribuição Normal.

Baixem e abram o script no RStudio:

```
script_url <- paste0(  
  "https://raw.githubusercontent.com/",  
  "mgaldino/estatistica-basica/main/",  
  "scripts/aula_07_distribuicao_amostral_tcl_lgn_alunos.R"  
)  
  
destino <- "aula_07_distribuicao_amostral_tcl_lgn_alunos.R"  
  
download.file(script_url, destino, mode = "wb")  
file.edit(destino)
```

Perguntas para responder no R

- 1 Em uma distribuição assimétrica, média, mediana e moda ficam no mesmo lugar?
- 2 O que acontece com a média acumulada quando o tamanho da amostra cresce?
- 3 A distribuição dos dados individuais precisa ser Normal para o TCL funcionar?
- 4 O que acontece com a distribuição amostral quando n aumenta?
- 5 Qual é a diferença entre desvio-padrão e erro-padrão?

A estatística descritiva resume a distribuição observada.

A inferência pergunta como a estimativa se comportaria em outras amostras possíveis.

LGN: a estimativa converge.

TCL: a distribuição amostral se torna previsível.

Erro-padrão: medimos a incerteza da estimativa.