# Exercícios — Amostragem

Métodos Quantitativos e Técnicas em Ciência Política I

2026-04-08

## Exercícios Teóricos

### Fácil

**1.** Defina, com suas palavras e com um exemplo de Ciência Política para cada:

a) População
b) Amostra
c) Parâmetro
d) Estimativa
e) Quadro amostral (sampling frame)

**2.** Classifique cada cenário abaixo como amostragem aleatória simples, estratificada, por conglomerados, sistemática ou de conveniência:

a) Um pesquisador entrevista as primeiras 50 pessoas que encontra na saída do metrô.
b) O IBGE sorteia 500 setores censitários no Brasil e entrevista todos os domicílios dentro deles.
c) Uma pesquisa eleitoral divide os eleitores por região (Norte, Nordeste, etc.) e sorteia proporcionalmente dentro de cada região.
d) Um cientista político seleciona cada 20º processo judicial em uma lista ordenada por data.
e) Todos os nomes dos 513 deputados são colocados em uma urna e 50 são sorteados.

**3.** Verdadeiro ou falso? Justifique as falsas.

a) Uma amostra de conveniência com 1 milhão de observações é mais confiável do que uma amostra aleatória com 2.000 observações.
b) O erro-padrão mede a variabilidade entre as estimativas de diferentes amostras.
c) O Teorema Central do Limite afirma que os dados na população seguem uma distribuição normal.
d) O tamanho da amostra necessário para uma pesquisa eleitoral depende mais da precisão desejada do que do tamanho da população.

### Médio

**4.** Uma pesquisa de opinião entrevista 1.500 pessoas por telefone fixo sobre a aprovação do governo. O resultado indica 62% de aprovação. Identifique:

a) Qual é a população-alvo?
b) Qual é o quadro amostral implícito?
c) Que grupo da população fica sistematicamente excluído?
d) Em que direção esse viés provavelmente afeta a estimativa? Justifique.

**5.** Explique a diferença entre a Lei dos Grandes Números (LGN) e o Teorema Central do Limite (TCL). O que cada um garante? Por que ambos são necessários para a inferência estatística?

**6.** Uma pesquisa quer estimar a proporção de brasileiros favoráveis a uma reforma tributária com margem de erro de 3 pontos percentuais e 95% de confiança. Uma pesquisa piloto indicou $p \approx 0{,}6$.

a) Calcule o tamanho da amostra necessário usando a fórmula $n = \frac{1{,}96^2 \times p(1-p)}{e^2}$.
b) Recalcule usando $p = 0{,}5$. Por que o resultado é maior?
c) Se quiséssemos margem de erro de 1 ponto percentual, qual seria o novo $n$? O que isso implica sobre o custo de pesquisas mais precisas?

## Difícil

**7.** O General Heleno criticou uma pesquisa XP/Ipespe que entrevistou 1.000 pessoas em um país com 149 milhões de eleitores, sugerindo que a amostra era pequena demais. Usando os conceitos de distribuição amostral, erro-padrão e TCL, construa um argumento explicando por que a crítica dele está equivocada. Inclua uma estimativa da margem de erro dessa pesquisa.

**8.** Um pesquisador quer estudar a participação política de jovens entre 18 e 24 anos no Brasil. Ele tem acesso ao cadastro eleitoral do TSE e considera duas estratégias:

- **Estratégia A:** Amostra aleatória simples de 2.000 eleitores de todo o cadastro.
- **Estratégia B:** Amostra estratificada por faixa etária, com sobre-amostragem de jovens (800 jovens + 1.200 dos demais estratos).

a) Na estratégia A, qual a probabilidade aproximada de que a amostra contenha pelo menos 200 jovens? (Jovens são ~15% do eleitorado.)
b) Qual estratégia é mais adequada para o objetivo do pesquisador? Justifique.
c) Na estratégia B, como o pesquisador deve proceder se quiser, além de analisar os jovens, estimar a opinião da população geral?

**9.** Um colega argumenta: "Se eu coletar dados de *todos* os usuários do Twitter que postaram sobre as eleições, não preciso me preocupar com inferência estatística, porque tenho a população inteira." Critique esse argumento.

# Exercícios em R

## Fácil

**10.** Execute o código abaixo e responda às perguntas.

```r
set.seed(123)

# População: notas de 10.000 alunos (média 6, desvio-padrão 2)
populacao <- rnorm(10000, mean = 6, sd = 2)

# a) Calcule a média e o desvio-padrão da população
mean(populacao)
sd(populacao)

# b) Sorteie uma amostra aleatória de 50 alunos e calcule a média
amostra <- sample(populacao, size = 50)
mean(amostra)

# c) Repita o sorteio 3 vezes. Você obtém a mesma média?
mean(sample(populacao, 50))
mean(sample(populacao, 50))
mean(sample(populacao, 50))
```

d) Por que as médias são diferentes a cada sorteio? Qual conceito da aula explica isso?

**11.** Complete o código abaixo para sortear uma amostra **estratificada** da população.

```r
set.seed(42)

# População com duas regiões
dados <- data.frame(
  id = 1:10000,
  regiao = sample(c("Norte", "Sul"), 10000, replace = TRUE, prob = c(0.3, 0.7)),
  renda = c(rgamma(3000, 2, 1) * 1000, rgamma(7000, 3, 1) * 1500)
)

# Amostra estratificada: 50 do Norte e 50 do Sul
amostra_norte <- dados[dados$regiao == "______", ]  # COMPLETE
amostra_norte <- amostra_norte[sample(nrow(amostra_norte), ___), ]  # COMPLETE

amostra_sul <- dados[dados$regiao == "______", ]  # COMPLETE
amostra_sul <- amostra_sul[sample(nrow(amostra_sul), ___), ]  # COMPLETE

amostra_estratificada <- rbind(amostra_norte, amostra_sul)

# Calcule a média de renda na amostra
mean(amostra_estratificada$renda)
```

## Médio

**12.** O código abaixo simula a Lei dos Grandes Números. Execute e responda.

```r
set.seed(7)

populacao <- rgamma(100000, shape = 2, rate = 1) * 1500
```

```r
parametro <- mean(populacao)

# Média acumulada conforme n cresce
tamanhos <- seq(10, 5000, by = 10)
amostra_grande <- sample(populacao, max(tamanhos))
medias_acumuladas <- sapply(tamanhos, function(n) mean(amostra_grande[1:n]))

plot(tamanhos, medias_acumuladas, type = "l", col = "steelblue", lwd = 2,
     xlab = "Tamanho da amostra (n)", ylab = "Média amostral",
     main = "Lei dos Grandes Números em ação")
abline(h = parametro, col = "red", lwd = 2, lty = 2)
legend("topright", legend = c("Média amostral", "Parâmetro verdadeiro"),
       col = c("steelblue", "red"), lwd = 2, lty = c(1, 2))
```

a) Descreva o que acontece com a linha azul conforme $n$ aumenta.
b) A partir de qual $n$ (aproximadamente) a média amostral se estabiliza perto do parâmetro?
c) Rode o código novamente **sem** `set.seed(7)`. O gráfico ficou idêntico? O padrão geral mudou? Explique.

**13.** Modifique o código da atividade de aula (TCL) para usar uma população com distribuição **uniforme** em vez de gamma.

```r
set.seed(42)

# MODIFIQUE: crie uma população com distribuição uniforme entre 0 e 10
populacao <- _____(100000, min = 0, max = 10)

# Verifique que a distribuição não é normal
hist(populacao, breaks = 50, main = "Distribuição da População (Uniforme)",
     col = "lightblue")

# Simule a distribuição amostral para n = 5, 30 e 100
for (n in c(5, 30, 100)) {
  medias <- replicate(1000, mean(sample(populacao, size = n)))
  hist(medias, breaks = 40, freq = FALSE,
       main = paste("Distribuição Amostral (n =", n, ")"),
       xlab = "Média amostral", col = "salmon")
  curve(dnorm(x, mean = mean(medias), sd = sd(medias)),
        add = TRUE, col = "darkred", lwd = 2)
}
```

a) A distribuição amostral se torna normal mesmo partindo de uma uniforme?
b) Para qual valor de $n$ a aproximação normal já parece boa?

## Difícil

**14.** O código abaixo calcula a **cobertura real** do intervalo de confiança de 95%: em quantas das 1.000 simulações o intervalo de fato contém o parâmetro verdadeiro?

```r
set.seed(99)

populacao <- rgamma(100000, shape = 2, rate = 1) * 1500
parametro <- mean(populacao)

n <- 50  # <-- MUDE: tente 15, 50 e 200
n_sim <- 1000
```

```r
contem_parametro <- replicate(n_sim, {
  amostra <- sample(populacao, n)
  media <- mean(amostra)
  ep <- sd(amostra) / sqrt(n)
  li <- media - 1.96 * ep
  ls <- media + 1.96 * ep
  parametro >= li & parametro <= ls
})

cat("Cobertura real:", mean(contem_parametro) * 100, "%\n")
```

a) Rode com $n = 15$, $n = 50$ e $n = 200$. A cobertura se aproxima de 95% em todos os casos?
b) Se a cobertura com $n = 15$ ficar abaixo de 95%, explique por quê. (Dica: o que o TCL exige sobre o tamanho da amostra?)
c) Modifique o código para calcular intervalos de 99% de confiança (troque 1,96 por qual valor?). A cobertura aumenta?

**15.** Neste exercício, você vai comparar o erro-padrão **teórico** com o erro-padrão **simulado**.

```r
set.seed(42)

populacao <- rnorm(100000, mean = 50, sd = 10)
sigma <- sd(populacao)

tamanhos <- c(25, 100, 400, 1600)

for (n in tamanhos) {
  # Erro-padrão teórico
  ep_teorico <- sigma / sqrt(n)

  # Erro-padrão simulado (desvio-padrão de 1.000 médias amostrais)
  medias <- replicate(1000, mean(sample(populacao, n)))
  ep_simulado <- sd(medias)

  cat("n =", n,
      "| EP teórico =", round(ep_teorico, 3),
      "| EP simulado =", round(ep_simulado, 3), "\n")
}
```

a) Os valores teórico e simulado são próximos?
b) Quando o tamanho da amostra quadruplica (de 25 para 100, de 100 para 400), o que acontece com o erro-padrão? Derive essa relação a partir da fórmula $\sigma_{\bar{X}} = \sigma/\sqrt{n}$.
c) Um pesquisador tem orçamento para entrevistar 400 pessoas. Se ele conseguisse mais verba para entrevistar 1.600, por quanto a margem de erro cairia? Vale o investimento?